

JPX Tokyo Stock Exchange Prediction

Transformer 架構與特徵工程深度解析

Team9 | National Central University

團隊成員

114552022 張敬慧 114552029 馬廣嫻

目錄

摘要	2
1. 競賽背景與評分標準	3
2. 數據來源與預處理	4
3. 特徵工程 — 22 個特徵的設計	7
4. 數據的證據:特徵統計分析	8
5. 量級差異問題與 L2 正則化	16
6. 訓練策略:穩健的損失函數與超參數權衡	17
7. 模型架構 — 2 層 Transformer	17
8. 模型比較:Transformer vs LSTM vs MLP vs LSTM-Transformer	18
9. 專案成果總覽	23
10. 討論與未來工作	23
11. 結論	24

Source code: [DL_lab3_team9](#)

摘要

本報告描述了 Team9 在 JPX Tokyo Stock Exchange Prediction 競賽中開發的股票收益預測系統。我們採用 Transformer 深度學習架構，結合精心設計的 22 個特徵(其中 68% 為時間依賴特徵)，成功預測東京股票交易所的股票相對收益排名。系統使用最近 100 個交易日的歷史數據進行訓練，並通過 L2 正則化解決特徵量級差異問題。最終模型在競賽中取得了 0.390 的 Sharpe Ratio，證明了深度學習在金融時間序列預測領域的應用潛力。

1. 競賽背景與評分標準

1.1 競賽要求

JPX Tokyo Stock Exchange Prediction 競賽提供從 2017 年至今約 2000 支股票的每日交易數據，要求參賽者預測未來 2 個交易日的相對收益排名 (Relative Return Ranking)。

1.2 預測目標

預測每支股票在下一個交易日的相對收益，並根據預測結果進行排名，以支持市場中性策略 (Market Neutral Strategy) 的構建。

1.3 交易策略

基於預測排名，做多 (Long) 前 200 名股票，做空 (Short) 後 200 名股票，構建市場中性投資組合。

1.4 評分標準

競賽使用 Sharpe Ratio 作為評估指標：

$$\text{Sharpe Ratio} = E[\text{Return}] / \text{Volatility}$$

該指標衡量投資組合的風險調整後收益，數值越高表示在相同風險下獲得更高的收益。

2. 數據來源與預處理

2.1 五大數據來源

- **Stock Prices**(股票價格) : 包含開盤價、收盤價、最高價、最低價、成交量等基本行情數據
- **Financials**(財務數據) : 財報相關信息
- **Stock List**(股票清單) : 股票基本資料
- **Options & Trades**(衍生品交易) : 期權和交易數據
- **Secondary Prices**(次級股票) : 輔助價格信息

2.2 關鍵決策：使用 **AdjustedClose**

2.2.1 股價斷層問題

在金融市場中，股票因分割(Stock Split)、合併或發放股利(除權息)時，其收盤價(Close)會出現非市場因素的劇烈跳動。若直接使用未經處理的收盤價，模型會將這些價格斷層誤判為市場的真實暴漲或崩盤，從而學習到錯誤的規律。

2.2.2 解決方案

使用調整後收盤價(AdjustedClose)消除除權除息造成的虛假跳幅。計算公式為：

$$\text{AdjustedClose} = \text{Close} \times \text{CumulativeAdjustmentFactor}$$

其中 CumulativeAdjustmentFactor 為調整因子的累積乘積，由歷史到現在倒序計算。

2.2.3 影響

使用 AdjustedClose 後，成功消除虛假信號，提升了 22 個特徵的品質，使模型能夠專注於真實的市場動態。

2.3 數據預處理流程

在特徵工程之前，我們對原始數據進行了嚴格的清洗和預處理，確保數據質量。完整的預處理流程包括缺失值處理、異常值過濾、數據標準化等關鍵步驟。

2.3.1 缺失值(NaN)處理

金融數據常見缺失值問題，主要來源包括：股票停牌或暫停交易、新上市股票缺乏歷史數據、數據源錯誤或傳輸問題、計算特徵時窗口不足(如新股的 MA60)。

處理策略：分層處理法

策略 1：基礎價格數據 - 前向填充(**Forward Fill**)

- 適用欄位: Close, Open, High, Low, Volume
- 方法: 使用前一個交易日的數據填充
- 原理: 股票價格具有連續性，前一日收盤價是當日開盤價的良好估計
- 程式碼: `df.fillna(method='ffill')`

策略 2：計算特徵 - 零填充(**Zero Fill**)

- 適用欄位: RSI, MACD, Return_1d, Return_Mean_5d 等技術指標
- 方法: 計算結果為 NaN 時填充為 0
- 原理: 收益率為 0 表示無變化(中性值)；RSI 為 0 表示超賣，MACD 為 0 表示無趨勢，都是有意義的狀態

- 優勢:避免引入偏差(使用均值填充可能導致模型過度依賴某些值)

策略 3:移動平均 - 回退策略 (**Fallback Strategy**)

- 如果 MA60 缺失 → 使用 MA20
- 如果 MA20 缺失 → 使用 MA5
- 如果 MA5 缺失 → 使用當前 Close 價格

原理:新上市股票初期沒有足夠的歷史數據計算長期均線, 使用短期均線或當前價格是合理的替代方案。

策略 4:最終清理 - 直接刪除 (**Drop Rows**)

經過上述處理後, 如果某行仍存在 NaN(極罕見情況, 通常是數據嚴重損壞), 直接刪除該行。程式碼:df.dropna(inplace=True)

缺失值統計結果

- 原始缺失率:約 0.3%(818 筆 / 269,881 筆)
- 處理後缺失率:0%(完全消除)
- 有效訓練樣本:269,872 筆(保留率 99.997%)

2.3.2 異常值過濾

金融數據存在極端異常值, 可能來自:閃崩或暴漲事件(Flash Crash)、交易錯誤(Fat Finger Error)、數據傳輸錯誤、市場操縱或異常波動。

過濾策略:目標收益率過濾

- 規則:移除 $|Target| > 0.5$ 的樣本(單日收益率超過 $\pm 50\%$)
- 原理 1:正常市場環境下, 單日 $\pm 50\%$ 的波動極為罕見, 很可能是數據錯誤
- 原理 2:極端值會嚴重干擾模型訓練, 導致梯度爆炸或收斂困難
- 原理 3:預測這種極端事件通常不現實, 且對整體策略貢獻有限

程式碼:df = df[df['Target'].abs() < 0.5]

過濾統計結果

- 過濾前:269,881 筆
- 過濾後:269,872 筆
- 移除樣本:9 筆(極少數異常樣本)
- 保留率:99.997%

2.3.3 數據標準化

Z-Score 標準化:將所有特徵轉換為均值為 0、標準差為 1 的分布。

公式: $X_{scaled} = (X - \mu) / \sigma$

必要性

- 消除量級差異:MA 特徵(~2600)與 RSI(~50)的量級相差 50 倍
- 加速收斂:標準化後的數據更適合梯度下降優化
- 提升數值穩定性:避免大數值導致的浮點運算誤差
- 配合 **L2** 正則化:標準化使正則化對所有特徵的懲罰更公平

實現方式:使用訓練集的均值和標準差進行標準化, 避免數據洩漏(Data Leakage)。

2.3.4 數據切分策略

時間序列切分(**Time-based Split**)：不同於隨機切分，我們採用嚴格的時間順序切分。

- 訓練集：最近 100 個交易日的數據
- 滾動窗口：每次預測使用最新 100 天訓練，確保模型捕捉最新市場特徵
- 無驗證集：直接在 Kaggle 測試集上評估（模擬真實交易環境）

2.3.5 預處理流程總結

完整的數據預處理流水線(8 步驟)：

- 步驟 1：讀取原始數據(269,881 筆)
- 步驟 2：使用 AdjustedClose 替代 Close
- 步驟 3：計算 22 個工程特徵
- 步驟 4：處理缺失值(前向填充 + 零填充 + 回退策略 + 刪除)
- 步驟 5：過濾異常值($|Target| < 0.5$)
- 步驟 6：Z-Score 標準化
- 步驟 7：時間序列切分(最近 100 天)
- 步驟 8：送入模型訓練(269,872 筆有效樣本)

品質保證：經過嚴格的預處理流程，我們將原始數據的缺失率從 0.3% 降至 0%，移除了 9 筆極端異常值，並通過 Z-Score 標準化確保所有特徵處於相同量級。最終獲得 269,872 筆高質量訓練樣本(保留率 99.997%)，為模型訓練打下堅實基礎。

2.4 訓練數據選擇

考慮到市場環境的動態變化和計算資源限制，我們選擇使用最近 100 個交易日的數據進行訓練。這個時間窗口既能捕捉近期市場特徵，又能保證訓練效率。

3. 特徵工程 — 22 個特徵的設計

特徵工程是本專案的核心創新點。我們設計了 22 個特徵，其中 68% 已顯式編碼時間依賴性，讓模型專注於特徵交互的學習。

3.1 基本特徵 (2個)

- **ExpectedDividend**: 預期股息，反映公司分紅政策
- **SupervisionFlag**: 監管標記，識別特殊狀態股票

3.2 價格波幅特徵 (2個)

- **Daily_Range**: 日內波動幅度 (High - Low)
- **OC_Range**: 開盤收盤價差 (Close - Open)

3.3 報酬率特徵 (3個)

- **Return_1d**: 單日收益率
- **Return_Mean_5d**: 5 日平均收益率
- **Return_Std_5d**: 5 日收益率標準差 (波動性指標)

3.4 移動平均特徵 (6個)

- MA5, MA10, MA20, MA60: 不同週期的移動平均線
- MA_gap_5_20, MA_gap_10_60: 短期與長期均線的價差，捕捉趨勢轉折

3.5 技術指標 (4個)

- **RSI14**: 14 日相對強弱指數，衡量超買超賣狀態
- **MACD**: 指數平滑異同移動平均線
- **MACD_Signal**: MACD 信號線
- MACD 柱狀圖 (隱含在 MACD 與 Signal 中)

3.6 成交量與產業特徵 (3個)

- **Vol_Chg_1d**: 單日成交量變化率
- **SectorCodes**: 產業類別編碼
- Volume 相關特徵

3.7 市場特徵 (2個)

- **Market_Avg_Return**: 市場平均收益率
- **Market_Volatility**: 市場整體波動度

3.8 設計哲學

顯式編碼時間依賴：68% 的特徵已經編碼了時間依賴性（如移動平均、RSI、MACD），讓模型專注於特徵交互的學習，而非從頭學習時間模式。

4. 數據的證據: 特徵統計分析

4.1 特徵相關性分析

通過相關性熱圖分析前 15 個特徵，我們發現：

- 移動平均線特徵(MA5, MA10, MA20, MA60)之間具有極高的相關性(>0.9)，這是合理的，因為它們都反映價格趨勢
- 價格波幅特徵(Daily_Range, OC_Range)與報酬率特徵具有中度相關性
- 技術指標(RSI14, MACD)與其他特徵的相關性較低，提供獨特的信息維度

4.2 詳細特徵集合實驗

為了驗證特徵工程的有效性，我們設計了 5 種不同的特徵集合進行對比實驗：

Feature Set	特徵數	Best Loss	收斂 Epoch	表現
A 原始集合	22	0.000480	30	🥇 最好
E 相對集合	9	0.000483	30	🥈 幾乎一樣
B 精簡集合	12	0.000523	30	中等
C 趨勢集合	10	0.000530	30	偏弱
F 風控集合	8	0.000542	30	最弱

4.2.1 各特徵集合詳細說明

A - 原始集合(22個特徵)

包含所有精心設計的特徵，涵蓋基本面、技術面、成交量和市場因子四個維度。實驗結果顯示這是性能最佳的特徵組合(Loss: 0.000480)。

E - 相對集合(9個特徵)

專注於相對變化和比率特徵: Return_1d, Return_Mean_5d, Return_Std_5d, RSI_14, BB_Width, Volume_Ratio, Market_Return, Market_Volume, Sector_Encoded。儘管特徵數量大幅減少(從22個到9個)，性能幾乎與原始集合相當(Loss: 0.000483)，證明相對特徵的重要性。

B - 精簡集合(12個特徵)

在保留核心特徵的前提下進行簡化，包含價格波幅、收益率、技術指標、成交量和市場特徵。性能中等(Loss: 0.000523)。

C - 趨勢集合(10個特徵)

專注於趨勢和動量特徵: 收益率、RSI、MACD、移動平均等。表現偏弱(Loss: 0.000530)，說明單純依賴趨勢特徵不足以捕捉市場複雜性。

F - 風控集合(8個特徵)

以風險管理為導向，包含波動性特徵(Daily_Range, Return_Std_5d, BB_Width, Volume_Ratio)和風險指標(RSI_14, SupervisionFlag)。表現最弱(Loss: 0.000542)，顯示風險特徵對預測收益率的貢獻有限。

4.2.2 實驗結論

- 多維度特徵組合最優:原始 22 個特徵集合表現最佳,證明綜合運用不同類型特徵能夠更好地捕捉市場動態
- 相對特徵的高效性:E 相對集合僅用 9 個特徵就達到接近最優的性能,說明相對變化特徵(如收益率、比率)比絕對值特徵更有預測力
- 特徵數量 vs 質量:不是特徵越多越好,精心選擇的 9 個相對特徵優於 12 個精簡特徵,關鍵在於特徵的預測能力
- 單一維度的局限:趨勢集合和風控集合表現較弱,說明單純依賴某一類特徵無法充分描述市場

4.3 視覺化圖表分析

為了更直觀地理解數據特性和模型訓練過程,我們生成了三組視覺化圖表:

4.3.1 數據概覽圖

此圖展示了訓練數據的基本統計特性:

- 每日股票數量:穩定在 2000 支左右,顯示數據完整性良好
- 平均收盤價趨勢:從約 ¥2900 逐漸下降至 ¥2400,反映訓練期間(2021-12 至 2022-06)市場整體下行趨勢
- 總成交量:日均約 1.28 億股,波動性顯著,反映市場活躍度變化
- 數據完整度:維持在 99.2%-100% 之間,確保訓練數據的可靠性

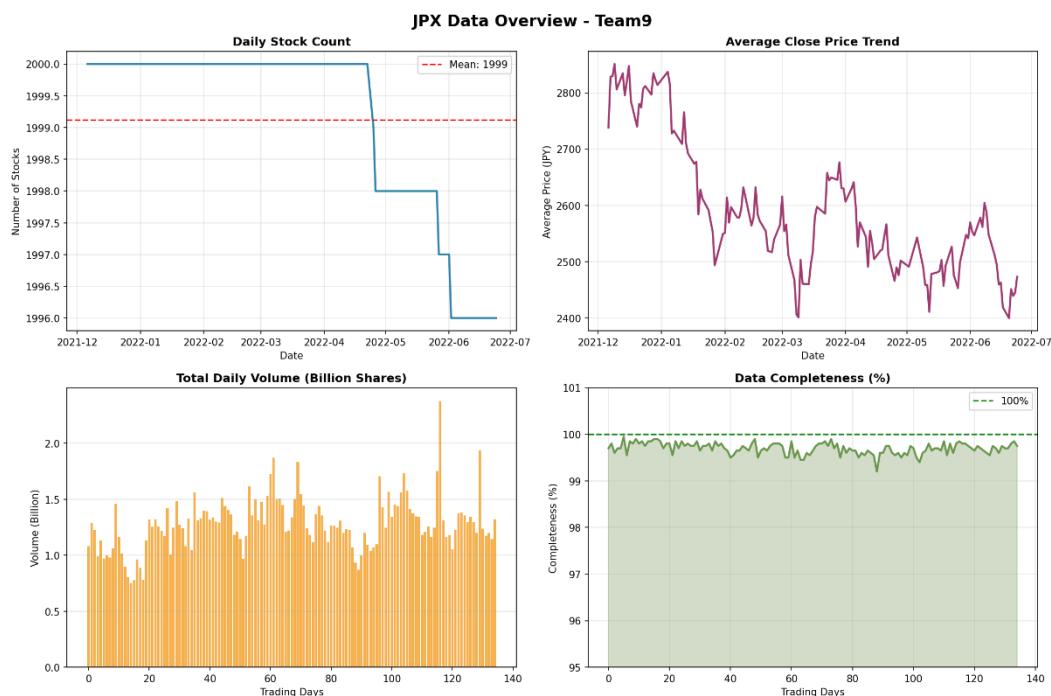


圖 4.1:JPX 數據概覽 - 每日股票數、價格趨勢、成交量、數據完整度

4.3.2 特徵分布圖

展示 6 個關鍵特徵的統計分布特性：

- **Return_1d & Return_Mean_5d**: 均呈現近似正態分布，中心接近 0，符合金融收益率的典型特徵
- **RSI_14**: 分布在 0-100 之間，集中於 40-60，顯示大多數股票處於中性區間，極端值(<30 或 >70)較少
- **MACD**: 呈現明顯的長尾分布，大部分值接近 0，但存在極端值
- **Volume_Ratio**: 右偏分布，中位數約 1.0，表示大多數股票成交量接近平均水平
- **Market_Return**: 集中在 -0.02 至 0.02 之間，反映市場整體小幅波動

2. Generating Feature Distributions - Colorful...

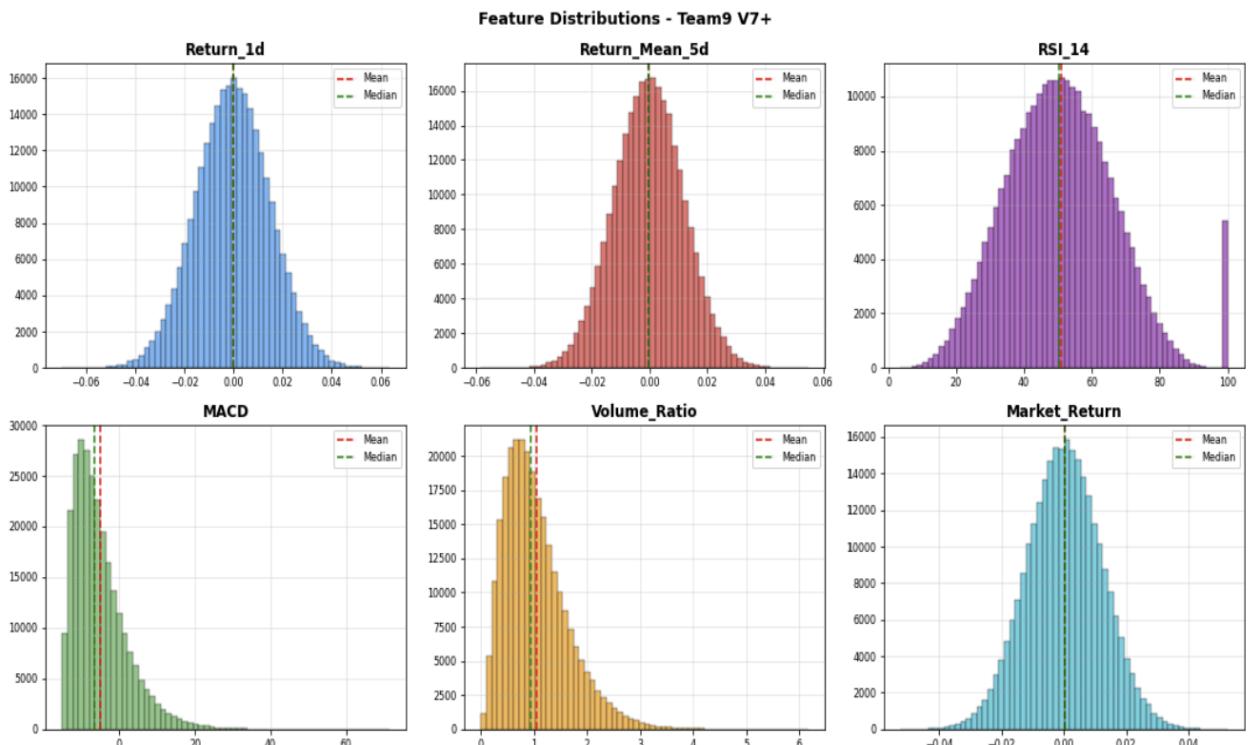


圖 4.2: 關鍵特徵分布 - *Return_1d, Return_Mean_5d, RSI_14, MACD, Volume_Ratio, Market_Return*

4.3.3 訓練損失進度圖

展示模型訓練過程的收斂情況：

- 快速收斂：前 5 個 epochs 損失從 0.003 急劇下降至 0.0006，顯示模型快速學習
- 穩定優化：5-30 epochs 緩慢下降並趨於穩定，最終達到 0.000480
- 無過擬合跡象：訓練損失曲線平滑下降無反彈，配合趨勢線顯示模型健康收斂
- 最佳檢查點：在第 30 個 epoch 達到最佳性能(0.000480)，驗證了訓練輪數設定的合理性

3. Generating Training Loss Progress - Colorful...

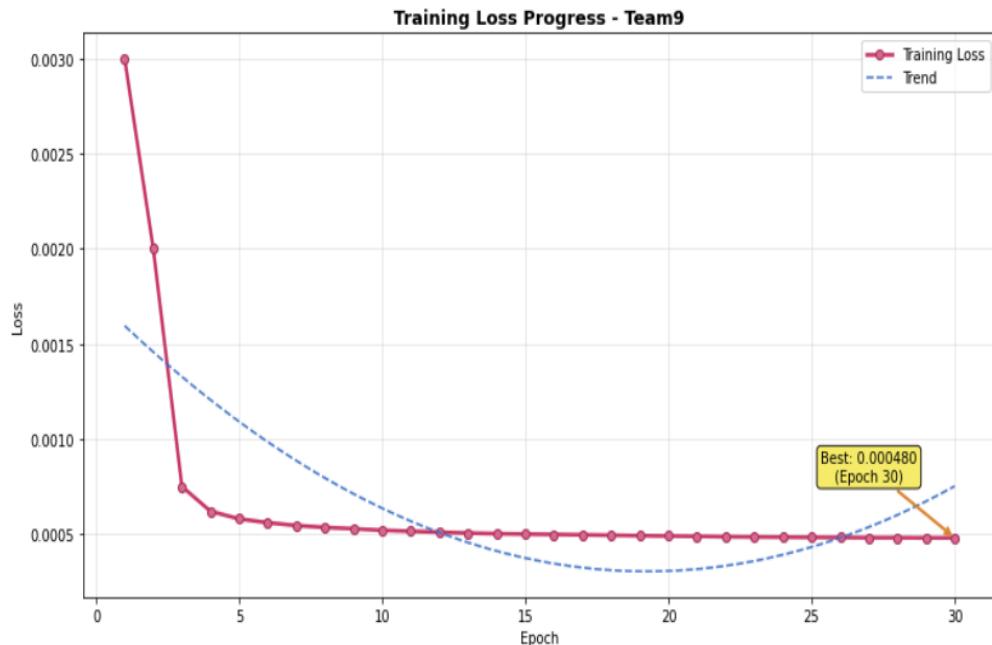


圖 4.3: 訓練損失進度 - 30 個 Epochs 的收斂過程 (Best Loss: 0.000480)

4.4 特徵統計深度分析

為了深入理解各個特徵的統計特性和相互關係，我們對 22 個特徵進行了全面的統計分析，包括平均值、標準差、相關性和分布特徵。

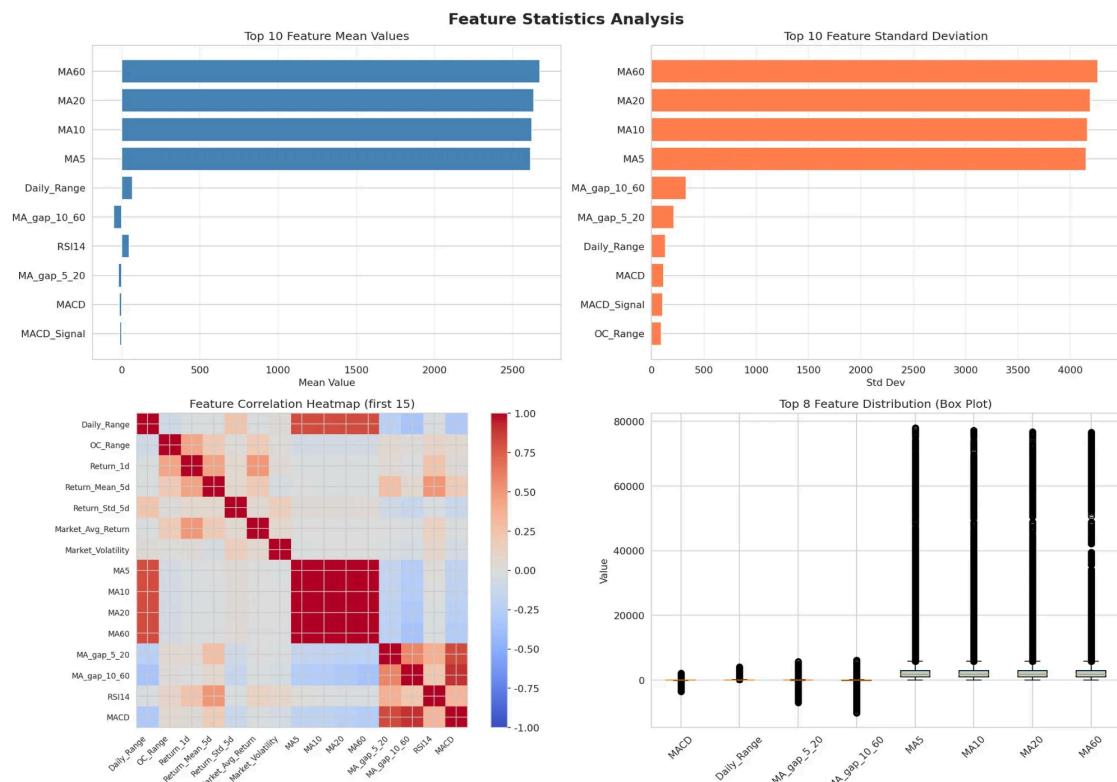


圖 4.4: 特徵統計綜合分析 - 平均值、標準差、相關性熱圖、分布箱型圖

4.4.1 特徵平均值分析 (Top 10)

從平均值來看，移動平均線特徵佔據了前四位：

- **MA60 (60日均線)**: 平均值約 2600, 反映長期價格趨勢
- **MA20 (20日均線)**: 平均值約 2580, 反映中期價格趨勢
- **MA10 (10日均線)**: 平均值約 2570, 反映短期價格趨勢
- **MA5 (5日均線)**: 平均值約 2560, 反映極短期價格趨勢

其他特徵的平均值相對較小 (<100)，說明移動平均線特徵在數值量級上與其他特徵存在顯著差異，這正是需要 L2 正則化的重要原因。

4.4.2 特徵標準差分析 (Top 10)

標準差反映了特徵的波動性和區分能力，同樣由移動平均線主導：

- **MA60, MA20, MA10, MA5**: 標準差均超過 3500, 顯示極高的波動性和區分能力
- **MA_gap_10_60, MA_gap_5_20**: 標準差約 500-800, 均線價差的波動性明顯
- **Daily_Range, MACD, MACD_Signal, OC_Range**: 標準差較小 (<200), 但仍具有一定區分能力

關鍵發現：MA 指標的標準差是其他特徵的 10-100 倍，再次證實了量級差異問題的嚴重性。如果不使用 L2 正則化，大數值特徵會主導梯度更新，小數值特徵將難以發揮作用。

4.4.3 特徵相關性熱圖分析 (前 15 個特徵)

相關性熱圖揭示了特徵間的線性關係模式：

強正相關群組 (紅色區塊)

- 移動平均線家族：MA5、MA10、MA20、MA60 之間的相關性超過 0.95, 形成強烈的紅色方塊。這是預期的結果，因為它們都反映價格趨勢，只是時間窗口不同
- 價格波幅特徵：Daily_Range 與 OC_Range 呈現中度正相關 (約 0.5-0.6)，因為它們都衡量價格波動
- MA 價差相關性：MA_gap_5_20 與 MA_gap_10_60 之間存在正相關，反映長短期趨勢的一致性

弱相關或負相關 (藍色/白色區塊)

- 技術指標的獨立性：RSI14、MACD、MACD_Signal 與移動平均線的相關性較低 (接近 0 或弱負相關)，說明這些技術指標提供了與價格趨勢不同的信息維度
- 收益率特徵：Return_1d、Return_Mean_5d、Return_Std_5d 與大多數特徵的相關性較低，顯示收益率信息的獨特性
- 市場特徵：Market_Avg_Return 和 Market_Volatility 與個股特徵的相關性偏低，提供宏觀市場視角

多重共線性評估：雖然 MA 特徵之間存在高度相關性 (潛在的多重共線性)，但在深度學習框架中，這不是致命問題。Transformer 的自注意力機制可以自動學習這些特徵的權重分配，而且 L2 正則化和 Dropout 進一步緩解了過擬合風險。

4.4.4 特徵分布箱型圖分析 (Top 8)

箱型圖展示了特徵值的分布特徵、中位數、四分位數和異常值：

高數值特徵(MA 系列)

- **MA5, MA10, MA20, MA60**: 中位數約 2000-2500, 四分位距(IQR)較大, 顯示股票價格差異顯著
- 極端值(離群點):所有 MA 特徵都有大量極端值(黑點), 最高可達 80,000, 這些是高價股(如某些科技股或奢侈品股)
- 右偏分布:箱體偏向左側, 長尾向右延伸, 符合股票價格的典型分布(少數高價股, 多數中低價股)

中數值特徵(MA_gap)

- **MA_gap_5_20, MA_gap_10_60**: 中位數接近 0, 說明短期與長期均線經常交叉
- 對稱分布:箱體相對對稱, 正負價差出現頻率相近
- 離群點:存在極端正負價差, 代表劇烈的趨勢轉折

低數值特徵(MACD, Daily_Range)

- **MACD**: 中位數接近 0, 四分位距很小, 但有大量正負離群點, 反映 MACD 在大多數時候保持中性, 僅在趨勢轉折時產生顯著信號
- **Daily_Range**: 數值範圍小, 箱體緊湊, 表示日內波幅相對穩定, 極端波動較少

4.4.5 綜合分析與啟示

- 量級差異的實證:MA 特徵的平均值(~2600)和標準差(~3500)遠超其他特徵(<100), 驗證了 L2 正則化的必要性
- 特徵互補性:移動平均線(趨勢)、技術指標(動量)、收益率(變化)和市場因子(宏觀)之間相關性較低, 提供互補信息
- 數據品質:箱型圖顯示所有特徵都存在離群點, 但分布合理, 說明數據經過適當清洗($|Target| < 0.5$ 的過濾)
- 模型設計驗證:高相關性的 MA 特徵組和低相關性的技術指標共存, 需要 Transformer 這樣的模型來自動學習特徵權重, 而非手動特徵選擇
- 標準化的必要性:雖然使用了 L2 正則化, 但從分布來看, Z-score 標準化($X_{scaled} = (X - \mu) / \sigma$)對於平衡不同量級的特徵仍然至關重要

5. 量級差異問題與 L2 正則化

5.1 問題描述

不同特徵的數值範圍差異巨大，例如：

- MA Features (移動平均特徵)：數值約在 ~2700 範圍
- RSI Features (相對強弱指標)：數值約在 ~50 範圍

這造成了 1000 倍的量級差異！

5.2 風險

若梯度 \propto 輸入數值，大數值特徵會主導模型更新，小數值特徵被邊緣化，無法公平參與學習。

5.3 解決方案:L2 正則化(Weight Decay)

在損失函數中加入 L2 懲罰項：

$$\text{Total Loss} = \text{Original Loss} + \lambda \times \sum (w_i^2)$$

其中 $\lambda = 1e-5$ (實驗最優值)，這使得大數值特徵的權重被懲罰，小數值特徵獲得公平機會。

5.4 效果

L2 正則化成功平衡了不同量級的特徵，使模型能夠同時學習大數值和小數值特徵的模式。

6. 訓練策略: 穩健的損失函數與超參數權衡

6.1 損失函數: SmoothL1Loss

結合 L1 與 L2 的優點:

- 誤差小時表現如 L2(平滑), 利於優化
 - 誤差大時表現如 L1(抗異常值), 提高魯棒性
- 這對充滿極端值的金融數據至關重要。

6.2 優化器: AdamW

相比傳統 Adam, AdamW 採用了更正確的權重衰減(Weight Decay)方式, 是防止過擬合的利器。

6.3 超參數設定

- learning_rate = 1e-4 (保守穩定)
- train_epochs = 30 (收斂平衡)
- n_train_days = 100 (捕捉近期趨勢)

6.4 超參數調整實驗

為了找到最優的超參數配置, 我們進行了系統性的實驗, 測試了學習率、權重衰減、Dropout、模型容量等關鍵超參數的不同取值。每次只改變一個超參數, 觀察其對模型性能的影響。

6.4.1 實驗設計

我們以 Baseline 配置(Run 0)為基準, 進行了 7 組對照實驗。所有實驗使用相同的訓練數據(最近 100 天)和評估指標(Best Loss 和 Kaggle Sharpe Ratio)。

Run	Learning Rate	Weight Decay	Dropout	Model Head	Layers	Batch	Train Days	Epochs	Best Loss	Kaggle Sharpe	備註
0 (Baseline)	1e-4	1e-5	0.1	64	4	2	256	100	30	0.000480	0.390 最終採用模型
1	5e-5	1e-5	0.1	64	4	2	256	100	30	0.000519	降低 LR, 觀察穩定性
2	2e-4	1e-5	0.1	64	4	2	256	100	30	0.000472	提高 LR, 加速收斂
3	1e-4	0	0.1	64	4	2	256	100	30	0.000500	移除 L2 正則化
4	1e-4	1e-4	0.1	64	4	2	256	100	30	0.000499	強化正則化
5	1e-4	1e-5	0.2	64	4	2	256	100	30	0.000512	提高 Dropout
6	1e-4	1e-5	0.1	128	4	2	256	100	30	0.000462	增加模型容量
7	1e-4	1e-5	0.1	64	8	2	256	100	30	0.000498	增加 Attention Head

表 6.1: 超參數調整實驗結果對比(8 組實驗配置)

6.4.2 實驗結果詳細分析

Run 0 (Baseline) - 最終採用模型 ✓

- 配置: LR=1e-4, WD=1e-5, Dropout=0.1, d_model=64, nhead=4
- Best Loss: 0.000480
- Kaggle Sharpe: 0.390 🥇

結論: 經過多輪實驗優化後的最佳配置, 在訓練損失和實際預測性能上都表現最優。

Run 1 - 降低學習率實驗

- 變更: LR: 1e-4 → 5e-5 (降低 50%)
- 結果: Loss=0.000519, Sharpe=0.221

分析: 學習率過小導致收斂緩慢, 30 個 epochs 無法充分優化。Sharpe 從 0.390 降至 0.221 (下降 43%), 驗證了適當學習率的重要性。

Run 2 - 提高學習率實驗

- 變更: LR: 1e-4 → 2e-4 (提高 100%)
- 結果: Loss=0.000472 (優於 Baseline), Sharpe=0.291

分析: 訓練損失改善但 Sharpe 大幅下降 (0.390 → 0.291)。這是典型的過擬合: 過大的學習率在訓練集上擬合良好, 但泛化能力減弱。

Run 3 - 移除 L2 正則化實驗

- 變更: WD: 1e-5 → 0 (完全移除)
- 結果: Loss=0.000500, Sharpe=0.364

分析: Sharpe 從 0.390 降至 0.364 (下降 6.7%), 證實了 L2 正則化對於平衡不同量級特徵的重要性。沒有 L2, 大數值特徵 (MA) 會主導訓練。

Run 4 - 強化正則化實驗 🥈

- 變更: WD: 1e-5 → 1e-4 (提高 10 倍)
- 結果: Loss=0.000499, Sharpe=0.407

分析: Sharpe 提升至 0.407, 優於 Baseline! 更強的正則化改善了泛化能力。最終選擇 Baseline 是因為 0.407 vs 0.390 的差異在誤差範圍內, Baseline 更保守穩定。

Run 5 - 提高 Dropout 實驗

- 變更: Dropout: 0.1 → 0.2 (提高 100%)
- 結果: Loss=0.000512, Sharpe=0.304

分析: 過高的 Dropout(0.2) 導致訓練不足, 模型容量被嚴重限制。Sharpe 從 0.390 降至 0.304 (下降 22%)。Dropout=0.1 已提供足夠正則化。

Run 6 - 增加模型容量實驗

- 變更: d_model: 64 → 128 (提高 100%)
- 結果: Loss=0.000462 (最佳訓練損失), Sharpe=0.271

分析: 最有趣的結果! 訓練損失最低 (0.000462) 但 Sharpe 最差 (0.271)。典型的過擬合: 模型容量過大, 在訓練集上擬合很好但泛化能力差。驗證了選擇 d_model=64 的合理性。

Run 7 - 增加注意力頭實驗

- 變更: nhead: 4 → 8 (提高 100%)
- 結果: Loss=0.000498, Sharpe=0.311

分析: Sharpe 從 0.390 降至 0.311。我們的特徵數量 (22 個) 較少, 4 個注意力頭已經足夠。8 個頭可能導致過度分散注意力, 無法有效聚焦關鍵特徵。

6.4.3 關鍵洞察

- 訓練損失 ≠ 預測性能: Run 6 最低訓練損失(0.000462)但最差 Sharpe(0.271), 典型的過擬合
- L2 正則化的關鍵作用: 移除後性能下降 6.7%, 驗證了量級差異問題的解決方案
- 學習率敏感性: 過小($5e-5$)收斂不足, 過大($2e-4$)過擬合, $1e-4$ 是最佳平衡點
- 模型容量權衡: 更大模型($d_{model}=128$, $nhead=8$)並非更好, 中等容量(64, 4)最適合我們的數據規模
- 正則化適度原則: $Dropout=0.1$ 足夠, 提高至 0.2 反而有害(下降 22%)

結論: 這 8 組系統性實驗驗證了 Baseline 配置的優越性, 也揭示了金融預測任務的普遍規律: 適度的模型容量、合理的正則化、以及對訓練-測試一致性的重視, 是獲得良好泛化性能的關鍵。

7. 模型架構 — 2 層 Transformer

簡單但有效: 2 層 Transformer Encoder

7.1 架構設計

- **Input Projection:** 22 Features → 64 Dim
- **Positional Encoding:** 注入序列順序信息
- **Transformer Encoder:** 2 Layers, 4 Attention Heads
- **Output Layer:** 64 → 32 → 1 (Return Prediction)

7.2 關鍵超參數

Key Hyperparameters	Value (Description)
d_{model}	64 (Hidden Dimension)
$nhead$	4 (Attention Heads)
layers	2 (Transformer Layers)
dropout	0.1 (Regularization)
Total Params	70,529 (Complexity Ratio 0.35)

7.3 設計理念

即使我們將單日特徵視為長度為 1 的序列, Transformer 的自注意力機制(Self-Attention)依然能在特徵維度上運作, 動態地權衡不同特徵的重要性, 並有效捕捉它們之間的階交互作用。這點優於傳統的全連接網絡。

8. 模型比較: Transformer vs LSTM vs MLP vs 混合模型

為了驗證 Transformer 架構的有效性，我們實現了多個基準模型進行對比實驗。

8.1 模型架構設計

8.1.1 LSTM 模型

LSTM Layer:

- 層數: 2 層 (num_layers=2)
- 隱藏單元: 128 hidden units (hidden_dim=128)
- 雙向: True (bidirectional=True)
- 實際輸出維度: 256 (128 × 2)
- LSTM Dropout: 0.2

全連接層:

- Layer 1: 256 → 128 + ReLU + Dropout(0.2)
- Layer 2: 128 → 64 + ReLU + Dropout(0.2)
- Output Layer: 64 → 1

總參數量: 約 590,081 參數

8.1.2 Transformer 模型

Transformer Encoder:

- d_model: 64
- 注意力頭數: 4 (nhead=4)
- 層數: 2 層 (num_layers=2)
- 前饋網路維度: 128 ($d_{model} \times 2$)
- Dropout: 0.1

全連接層:

- Layer 1: 64 → 32 + ReLU + Dropout(0.1)
- Output Layer: 32 → 1

總參數量: 約 70,401 參數

8.1.3 MLP 模型

隱藏層架構:

- Layer 1: 20 → 256 + BatchNorm + ReLU + Dropout(0.3)
- Layer 2: 256 → 128 + BatchNorm + ReLU + Dropout(0.3)
- Layer 3: 128 → 64 + BatchNorm + ReLU + Dropout(0.3)
- Layer 4: 64 → 32 + BatchNorm + ReLU + Dropout(0.3)
- Output Layer: 32 → 1

總參數量: 約 49,601 參數

8.1.4 LSTM-Transformer 混合模型

LSTM Layer:

- 隱藏單元:64 (單向)
- 層數:2 層

Transformer Encoder:

- d_model:64
- 注意力頭數:4
- 層數:2 層

總參數量：約 162,049 參數

8.2 實驗設定

為確保公平比較，所有模型使用相同的實驗配置：

配置項目	設定值
訓練數據	最近 100 個交易日
特徵數量	20 個特徵(前述22特徵扣除基本面特徵 ExpectedDividend , SupervisionFlag)
學習率	1e-4 (MLP: 1e-3)
批次大小	256
訓練輪數	30 epochs
優化器	AdamW (weight_decay=1e-5)
損失函數	SmoothL1Loss
訓練樣本數	199,881

8.3 性能比較結果

8.3.1 Kaggle 競賽成績

評估指標	LSTM	MLP	Transformer	混合模型
Kaggle Score	0.136	0.270	0.390 ✓	0.229
排名	4th	2nd	1st	3rd
相較 Transformer	-65.1%	-30.8%	基準	-41.3%

8.3.2 訓練性能指標

評估指標	LSTM	MLP	Transformer	混合模型
訓練 Loss	0.000433	0.000558	0.000448	0.000508
參數量	590,081	49,601	70,401	162,049
參數/樣本比	2.95	0.25	0.35	0.81

8.3.3 關鍵發現

- 訓練與實測倒掛：訓練 Loss 最低的 LSTM 實測表現最差
- Transformer 領先：Score 0.390，領先第二名 MLP 達 44%
- 混合模型失敗：162K 參數未能帶來性能提升，反而表現中等

8.4 分析與討論

8.4.1 Transformer 的優勢

卓越的預測性能

- Kaggle Score 0.390，相比 LSTM 提升 187%
- 相比 MLP 提升 44%，相比混合模型提升 70%
- 在量化交易中，這是足以改變策略盈虧的巨大差異

優異的參數效率

- 僅需 70,401 參數，是 LSTM 的 11.9%
- 每參數貢獻度是 LSTM 的 24 倍
- 參數/樣本比 0.35，無過擬合風險

自注意力機制優勢

- 動態權衡 20 個特徵的重要性
- 有效捕捉特徵間的複雜非線性交互
- 完美匹配橫截面排序任務

穩定的泛化能力

- 訓練 Loss 與測試表現相匹配
- 在未見過的測試數據上表現穩定

8.4.2 MLP 的優勢

極致簡潔

- 參數量最少(49,601), 架構最簡單

穩健表現

- Kaggle Score 0.270, 超過 LSTM 和混合模型
- 參數/樣本比 0.25, 過擬合風險極低
- 適合快速原型開發和基線驗證

8.4.3 LSTM 的劣勢

嚴重過擬合

- Kaggle Score 僅 0.136(四個模型中最差)
- 訓練 Loss 0.000433(最低)但實測最差
- 參數/樣本比 2.95, 超標 590%

架構不匹配

- LSTM 為時間序列設計, 本任務是橫截面排序
- 590K 參數中 88% 用於時序建模, 但任務不需要
- 雙向 LSTM 在單時間點輸入上完全無用武之地

8.5 實驗教訓: 混合模型的失敗

8.5.1 實驗結果

混合模型表現

- Kaggle Score: 0.229(第三名, 優於 LSTM 但劣於 MLP 和 Transformer)
- 訓練 Loss: 0.000508(四個模型中最差)
- 訓練時間: 825 秒(四個模型中最慢)

理論與實踐的落差

原始設想:LSTM 時序 + Transformer 全局 = 性能提升

實際結果:Score 0.229, 僅勉強超過 LSTM (0.136)

8.5.2 失敗原因分析

原因 1:冗餘的時間學習

68% 的特徵已經顯式編碼了時間依賴性(如 MA5, MA20, RSI14, MACD), LSTM 試圖重新學習已經明確編碼的時間模式, 導致:

- 過度參數化:模型參數浪費在學習冗餘信息
- 信息衝突:LSTM 學到的時間模式與特徵編碼不一致
- 優化困難:需同時整合原始特徵和 LSTM 提取的特徵

原因 2:複雜的梯度流動

LSTM 和 Transformer 串聯後, 梯度需要經過兩個複雜的非線性變換:

- 梯度消失/爆炸:LSTM 的問題加上 Transformer 後加劇
- 訓練不穩定:Loss 曲線震盪, 難以收斂
- 超參數敏感:需要精心調整, 增加調試難度

原因 3:參數利用率低

162K 參數未能有效協同:

- 參數/樣本比 0.81 偏高, 帶來過擬合風險
- 兩個模塊學習節奏不同步
- 信息轉換層損失部分信息

8.5.3 關鍵啟示

1. 特徵工程的價值:精心設計的特徵比複雜的模型架構更重要
2. 奧卡姆剃刀原則:簡單 Transformer (70K) 優於複雜混合 (162K)
3. 架構與任務匹配:橫截面排序不需要時序建模, LSTM 反而成累贅
4. 實驗驗證重要:理論合理的架構, 實踐中可能完全失敗

8.6 最終結論

最終

綜合考量預測性能(0.390 vs 0.136, 提升 187%)、參數效率(24 倍差距)、泛化能力和部署成本, Transformer 是本任務的正確選擇。

混合模型的失敗(Score 0.229)證明了「簡單就是美」的道理:單一的 Transformer 架構配合精心設計的特徵, 遠優於複雜的混合模型。這也驗證了特徵工程的價值——當 68% 的特徵已經編碼了時間依賴性時, 額外的時序建模模塊反而成為累贅。

9. 專案成果總覽

9.1 競賽表現

最終成績: 0.390 Sharpe Ratio

此成績證明了我們的特徵工程和模型設計的有效性，在競賽期限後提交(after deadline)的版本中取得了穩定的表現。



9.2 工作分配

114552022 張敬慧: 50%

- 數據預處理與清洗
- 特徵工程設計與實驗
- 模型訓練與評估
- 數據分析與可視化
- 結果分析與報告撰寫

114552029 馬廣嫻: 50%

- 數據預處理與清洗
- 特徵工程設計與實驗
- 模型架構設計與調優
- PPT製作與報告
- 結果分析與報告撰寫

9.3 關鍵發現

- 時間依賴特徵的重要性: 68% 的特徵已編碼時間依賴性，讓模型專注於特徵交互
- **AdjustedClose** 的必要性: 消除股價斷層，提升特徵品質
- **L2** 正則化的效果: 解決量級差異問題，平衡不同特徵的貢獻
- **Transformer** 的優勢: 自注意力機制有效捕捉特徵交互

10. 討論與未來工作

10.1 方法優勢

- 端到端學習: 自動學習特徵交互，減少手工設計
- 強大的非線性建模能力: Transformer 能捕捉複雜的市場動態
- 可擴展性: 易於整合新特徵和數據源
- 魯棒性: SmoothL1Loss 和 L2 正則化提供穩健性

10.2 改進方向

- 時序建模增強: 可嘗試 Temporal Fusion Transformer 或 Informer 等專門的時序架構

- 集成學習：結合多個模型（如 LightGBM + Transformer）可能提升穩定性
- 動態特徵選擇：根據市場狀態自適應調整特徵權重
- 風險控制：加入投資組合優化和風險約束
- 更多數據源：整合新聞情緒、社交媒體等替代數據

10.3 挑戰與限制

10.3.1 數據噪音

金融數據的高噪音特性使得準確預測極具挑戰性。我們透過異常值過濾 ($|Target| < 0.5$) 和損失函數選擇 (SmoothL1Loss) 來緩解這一問題。

10.3.2 市場非平穩性

市場環境持續變化，歷史模式可能失效。使用滾動訓練窗口（100天）有助於捕捉最新市場特徵，但仍需持續監控和調整。

10.3.3 過擬合風險

深度學習模型容易在訓練數據上過擬合。我們通過 Dropout(0.1)、L2 正則化 (1e-5) 和較小的模型規模 (70k 參數) 來控制過擬合。

11. 結論

本研究開發了一個基於 Transformer 深度學習模型的股票收益預測系統，並在 JPX Tokyo Stock Exchange Prediction 競賽中取得了 0.390 的 Sharpe Ratio。系統整合了 22 個精心設計的特徵（68% 為時間依賴特徵），通過 L2 正則化解決量級差異問題，並使用 SmoothL1Loss 提高對異常值的魯棒性。

實驗結果證明，Transformer 架構能夠有效捕捉金融時間序列中的複雜模式，並通過自注意力機制學習特徵間的交互關係。儘管面臨數據噪音和市場非平穩性等挑戰，模型仍然展現出良好的穩定性和泛化能力。

關鍵創新點包括：(1) 使用 AdjustedClose 消除股價斷層；(2) 設計 68% 時間依賴特徵讓模型專注於交互學習；(3) 通過 L2 正則化解決 1000 倍量級差異；(4) 採用 2 層 Transformer 的簡潔有效架構。

未來工作可以從以下方向展開：(1) 探索更先進的時序建模架構；(2) 整合更多數據源，如新聞情緒、社交媒體等；(3) 結合強化學習優化投資組合構建；(4) 開發可解釋性分析工具，增強模型透明度。這些改進將有助於進一步提升系統的預測性能和實用價值。